Bagaimana membagikan data produksi tanpa membocorkan identitas?

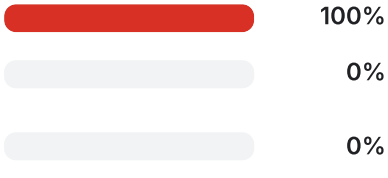
Pipeline anonimisasi pada data produksi SIMULASI (39 operator, 4.500 baris). Python + DuckDB.

100% → 0%
baris unik (kombinasi terketat), k minimum 1 → 5

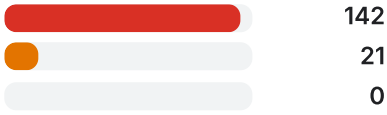
100% → 0%
nama operator pulih via serangan kamus (HMAC berkunci)

18 jam
kerja dihemat per tahun (perkiraan)

Serangan kamus pada nama operator



Catatan bebas yang masih berisi identitas



Korelasi tren per generalisasi



Rekomendasi perkiraan

- Pakai kelima metode sekaligus; hindari hash tanpa kunci dan regex saja.
- Pilih generalisasi mingguan; uji ulang pada data nyata dengan izin.

DATA SIMULASI. Risiko sisa: 38 dari 39 kode operator masih tersambung bila daftar jaga mingguan diketahui; skala indeks bukan pengaman penuh; differential privacy tidak dipakai.

Verifikasi: SQL vs pandas 26 dari 26; validasi 10 dari 10; pindai 8 dari 8. **Repo:** github.com/bagusbernadi/Project-24-Privacy-Preserving-Data-Pipeline